

Topic Progress Research

使用 Prompt 与完整示例输出：LLM 上下文压缩

本次调研范围（默认固定参数）

项目	默认值	本次含义
论文时间范围	最近 5 年	正式发表会议论文；本检索快照覆盖 2023-2026。
论文类型	published_only=true	主池不收录预印本或仅投稿论文；Findings 单列为正式会议附录。
论文来源	会议论文集/官方页	优先 ACL Anthology、NeurIPS/ICLR/AAAI/ICML 官方 proceedings；CCFDDL 只用于发现会议。
开源项目	Top 20	按相关性、Stars/Forks、活跃度排序；本例均为 GitHub。
项目活跃窗口	12 months	独立项目优先近期活跃；论文关联仓库不受此限制。
社区技术资料	community_sources=true	第三类结果：搜索发现后打开原文，汇总博客、知乎、公众号等。
社区资料上限	max_community_sources=10	去重后的社区/技术媒体条目上限；不与论文或项目混排。
相近方向	include_close=true	保留 RAG、soft-token、KV-cache、Agent/MCP/tool-output 等邻近候选。

如何修改范围

直接在调用语句中使用自然语言，或追加 key=value 参数。

使用 \$topic-progress-research 调研 LLM 上下文压缩。
调研上下文压缩近10年发表的论文；max_projects=30；include_close=false；community_sources=true；max_community_sources=15。

可覆盖参数：paper_years=10、project_recency=24 months、max_projects=30、published_only=true/false、include_close=true/false、community_sources=true/false、max_community_sources=15。

检索词扩展

核心	近邻	工程生态
context compression; prompt compression; long-context compression	RAG compression; soft-token memory; KV-cache compression	agent context management; tool-output compression; CLI proxy; MCP context

来源与判定规则

会议发现入口：[CCFDDL](#)；CCF 分级依据：[CCF 人工智能目录](#)。论文标题链接至官方出版页，项目名称链接至公开源代码主页。第三类资料必须链接到实际文章，搜索引擎仅作发现，不将 snippet 当证据。Stars/Forks 是 2026-09-22 检索快照，非实时数值。

完整论文候选池

共 20 篇已发表会议论文。CCF 标签按当前 CCF AI 目录标注；“未列入”不等同于低等级。论文与代码链接均可直接点击。

会议/CCF	论文与出版来源	已验证关联代码/实验来源
EMNLP 2023 B	LLMLingua: Compressing Prompts for Accelerated Inference of Large Language Models	microsoft/LLMLingua
EMNLP 2023 B	Selective Context: Reducing Text Context Without Altering Tasks	
EMNLP 2023 B	AutoCompressors: Summary Tokens Meet Retrieval	princeton-nlp/AutoCompressors
EMNLP 2023 B	Learning to Compress Prompts with Sentinel Tokens	
EMNLP Findings 2023 B	TCRA-LLM: Token Compression with Ranking-Aware Learning	
会议/CCF	论文与出版来源	已验证关联代码/实验来源
NeurIPS 2023 A	Learning to Compress Prompts with Gist Tokens	jayelm/gisting
ICLR 2024 未列入当前 CCF AI 目录	RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation	carriex/recomp
ICLR 2024 未列入当前 CCF AI 目录	In-Context Autoencoder for Context Compression in a Large Language Model	getao/icae
ACL 2024 A	LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression	microsoft/LLMLingua
ACL Findings 2024 A	LLMLingua2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression	microsoft/LLMLingua
会议/CCF	论文与出版来源	已验证关联代码/实验来源
AAAI 2025 A	CPC: Compressing Prompts for Efficient LLM Inference	
AAAI 2025 A	AttnComp: Token Compression via Attention-Driven Relevance	
ACL 2025 A	DAC: Dynamic Adaptive Compression for Efficient Long-Context LLMs	
ACL 2025 A	500xCompressor: Extreme Context Compression for LLMs	ZongqianLi/500xCompressor
ACL 2025 A	Pretraining Context Compressors for Long-Context Language Models	
会议/CCF	论文与出版来源	已验证关联代码/实验来源
ACL 2026 A	GMSA: Guided Multi-Stage Attention for Context Compression	
ACL 2026 A	Attn-GS: Attention-Guided Selection for Context Compression	
ACL 2026 A	SARA: Scalable Adaptive Retrieval-Aware Compression	Ahren09/SARA
ICML 2026 A	ACON: Adaptive Context Compression	microsoft/acon
ACL Findings 2026 A	BRIEF-Pro: Budgeted Retrieval and Information-Efficient Prompting	

完整开源项目 Top 20

全部为 GitHub 来源；按主题相关性与生态信号排序。此表不替代对维护质量、安全性或许可证适配性的人工审查。

排名	项目与来源	Stars	Forks	许可证	最近活动	主要边界
1	RTK rtk-ai/rtk	81,336	5,153	Apache-2.0	2026-09-21	Coding-agent shell/tool output
2	LLMLingua microsoft/LLMLingua	6,689	428	MIT	2026-09-10	Prompt/RAG compression
3	Chisle JayPokale/Chisle	494	32	MIT	2026-09-19	Coding-agent text/tool output
4	Context Engine Context-Engine-AI/Context-Engine	402	55	MIT	2026-07-08	Agent context/MCP
5	AutoCompressors princeton-nlp/AutoCompressors	336	27	未声明	2024-09-09	Soft-token compression
排名	项目与来源	Stars	Forks	许可证	最近活动	主要边界
6	leanctx jia-gao/leanctx	326	5	MIT	2026-08-22	Context reduction
7	Gist Tokens jayelm/gisting	322	26	Apache-2.0	2025-02-14	Gist-token compression
8	SARA Ahren09/SARA	262	0	Apache-2.0	2026-07-23	Adaptive compression
9	tokenfold snchimata/tokenfold	206	35	Apache-2.0	2026-09-21	Token/context folding
10	ICAE getao/icae	178	19	CC0-1.0	2024-05-11	Memory-slot compression
排名	项目与来源	Stars	Forks	许可证	最近活动	主要边界
11	RECOMP carriex/recomp	149	8	MIT	2026-01-06	RAG compression
12	ACON microsoft/acon	116	17	MIT	2025-10-14	Adaptive context compression
13	Supercompress Supercompress/Supercompress	79	23	MIT	2026-09-08	Prompt/context compression
14	500xCompressor ZongqianLi/500xCompressor	64	8	未声明	2026-03-09	Paper implementation
15	Distil dshakes/distil	16	3	未声明	2026-09-21	Tool output distillation
排名	项目与来源	Stars	Forks	许可证	最近活动	主要边界
16	context-compress Open330/context-compress	8	0	MIT	2026-09-12	Context compression
17	tare mstuart/tare	4	1	MIT	2026-09-21	Agent/tool context
18	capsule hakiyaka/capsule	4	0	MIT	2026-09-19	Context packaging
19	context-compressor xbyteid/context-compressor	1	0	MIT	2026-07-06	Context compression
20	mcp-guardian S1LV3RJ1NX/mcp-guardian	0	1	MIT	2026-07-14	MCP context guard

技术社区与媒体信号（第三类来源）

以下条目由搜索引擎发现后访问原文形成简要总结。它们用于补充工程线索和实践观点，不作为论文结论、性能指标或代码质量的主证据。知乎与公众号同样按此格式收录；当前示例以可公开访问并能核验的技术博客为主。

文章与直链	平台/类型	日期	简要技术总结	局限
大模型RAG的上下文压缩与过滤	博客园 / 技术博客	2025-10-11	给出 RAG 检索后过滤、摘要、结构化字段提取和组合策略的工程示例。	个人技术文章；代码与性能结论需自行复核。
Tool Output Compression: The Injection Decision That Shapes Context Quality	Tian Pan / 工程博客	2026-04-20	从 Agent 工具输出注入讨论字段提取、模型摘要和原始注入的取舍。	作者观点；部分内容仅会员可见。
RAG 上下文压缩实战 - 用更少 Token 传递更多信息	DarryPy / 技术博客	2026-07-14	比较规则过滤、重排截断、LLM 提取和 LLMLingua 等工程路线。	个人实战文章；指标应回溯原始实验。
LLM Agent 上下文压缩算法	Hugo Zhu's Blog / 技术博客	2026	梳理 Agent 上下文膨胀与压缩算法演进，作为工程线索。	页面可访问性与日期应在使用时再核验。

读取与筛选建议

论文池刻意追求召回率：先依任务边界删除 adjacent 候选，再按会议、CCF、是否有复现实验和方法路线筛选。项目榜可先按 Stars/Forks、许可证和最近活动初筛，再阅读 README、issue 和发布记录。

每条论文与项目行都已携带对应来源链接；代码为空表示本次未验证到官方或论文明确关联的公开实现，不代表不存在代码。